报告正文

一、立项依据

（一）研究意义

飞行器装备研发与博弈对抗验证是现代国防科技体系建设的制高点领域，其试验验证过程涵盖从航电系统半实物仿真、发动机高空台试验到实战化对抗演练的全谱系环节。这一过程产生海量的多源异构数据——包含飞行参数时间序列（迎角、侧滑角、马赫数、三轴过载、舵面偏度等）、遥测 PCM 数据流、雷达 RCS 散射特征数据流、飞控系统总线数据等多模态信息，承载着飞行器气动性能评估、结构完整性检验、动力系统可靠性验证、体系效能检验和战法创新探索等关键使命。然而，当前飞行器试验数据处理领域长期面临四大核心痛点：

第一，多源试验数据异构性强、语义割裂。飞行器试验数据来源极为广泛，涵盖机载传感器、外测设备、地面遥测站、半物理仿真平台、试验台和事后数据处理系统等。以某型战斗机试飞为例，单次起落便同时产生飞行参数记录器（FDR）的 KHz 级高频振动数据，这些数据在物理单位（工程单位制与国际单位制混用）、采样频率（从 1Hz 的 GPS 位置到 KHz 的振动信号）、时空戳对齐（机载时钟与地面时钟可能存在 ms 至 s 级偏差）和直观的工程语义上存在天然鸿沟。传统处理方式依赖人工判读和定制化转换脚本，单架次处理极度繁琐，此外，不同试验类型之间的数据关联更为薄弱——例如，风洞试验数据与飞行试验数据的相关性分析（即“天地相关性”问题）长期依赖经验公式修正，缺乏统一的语义表征框架来实现跨设施、跨状态的数据融合。这些异构数据以“数据孤岛”形态分散存储于各专业科室的独立数据库中，彼此之间缺乏统一的语义表征桥梁。如何建立跨格式、跨模态、跨试验设施的统一表征框架，实现多源异构数据的语义对齐与融合，是提升飞行器试验数据利用效能的首要挑战。

第二，异常标注可信度低，深层关联难以人工挖掘。飞行器试验中的异常检测与根因分析是试飞安全监控和适航审定的核心任务。典型异常

场景包括发动机喘振先兆识别、结构颤振边界判定、航电系统隐性故障诊断、飞控系统作动器瞬态振荡检测等。当前异常标注高度依赖资深试飞工程师和领域专家的经验判断，标注过程受个人认知偏差和学科背景影响显著——同一段过载异常曲线，气动专业可能归因于突风载荷激励，结构专业可能判定为弹性模态耦合，而飞控专业可能认定为作动器控制律切换瞬态。更深层的挑战在于，飞行器故障往往呈现“跨系统-跨时域-跨工况”的复杂因果链网络。以发动机振动超限为例，其根因可能源于：进气道流场畸变（气动）→压气机叶片非定常失速（叶轮机械）→转子不平衡力传导至机匣（转子动力学）→最终耦合短舱安装节刚度退化（结构强度），这一多层次因果链涉及气动、动力、结构三个学科领域，且故障传导时间跨度可能长达数十飞行小时。另一个典型案例是飞行器结构颤振问题：颤振边界在飞行包线内的演化可能同时受马赫数、高度、外挂构型、燃油状态和结构老化程度等多个因素的耦合影响，其先兆信号往往分散在振动频谱的多个频段内，与正常飞行振动、发动机激励和大气湍流响应相互交织。这种多维度、非线性的深层关联完全超出了人工经验分析的认知边界——一名工程师可能精通本专业领域的数据特征，但难以同时掌握气动、结构、飞控、动力等多学科的知识体系来实现跨领域的异常溯源。此外，专家知识具有高度隐性和个人化特征，资深工程师退休或调离往往导致宝贵的故障诊断经验流失，难以实现规模化的知识复用和传承。

第三，传统数据处理方法效率低，决策支撑能力弱。从飞行原始数据采集到形成可供决策者使用的分析结论（如“是否可以继续扩展飞行包线”“是否需要进行结构检修”“战术战法是否需要调整”），传统流程通常需要经历工程量纲转换（将二进制总线数据解析为物理量）、野值剔除与数据清洗（处理传感器丢帧、电磁干扰脉冲等）、关键参数趋势分析与超限判读、异常事件排查与故障归零分析、综合评估报告编撰，全周期常使用数天。在这一流程中，各环节高度依赖人工逐步执行，工具链碎片化（不同专业使用不同的分析软件和脚本），整个过程的自动化程度低、可重复

性差、版本管理混乱。在博弈对抗验证等时效性要求极高的场景下，这种“数据丰富但信息贫乏”的困境直接制约了快速决策能力。以红蓝对抗演练后的复盘推演为例，一场大规模对抗可能产生数十 GB 的交战数据（包括各平台的航迹数据、武器发射事件、电子战干扰记录、通信截获信息等），指挥官需在数小时内从这些海量数据中提取战术规律、识别敌方作战模式、发现己方薄弱环节并形成改进方案。传统的数据处理方式完全无法满足这一时效性要求，导致大量宝贵的对抗经验数据未能得到及时有效的利用，对抗演练的“发现问题-分析原因-改进战术”闭环周期过长，严重制约了飞行器作战能力的敏捷迭代和飞行员战术素养的快速提升。

第四，特殊场景下数据安全与自主可控的刚性约束。飞行器试验数据涉及气动外形、隐身特性、发动机性能包线、武器系统精度、航电架构、电子战能力等核心机密参数，属于国家技术秘密，严禁以任何形式传输至公共网络或云端服务。商用大模型（如 ChatGPT、Claude、Gemini 等）普遍存在数据回传云端服务器的风险，且其安全过滤机制不透明，模型提供商所在国的法律环境可能要求其配合情报机构获取用户数据。2023 年，某国际知名航空航天企业即发生工程师误将翼型设计参数输入 ChatGPT 进行格式转换的严重泄密事件，引发全球军工行业对商用 AI 服务安全性的系统性排查。此外，商用大模型还存在模型幻觉不可控的致命缺陷——在无可靠事实支撑的情况下生成看似合理但实则错误的结论。在飞行器试验场景中，一个虚构的故障归因或错误的安全评估可能导致灾难性后果。更值得警惕的是，商用模型的训练数据来源不透明，可能被投毒或植入偏见，在高风险军事决策场景中产生不可预知的风险。因此，在涉密内网环境下构建完全本地化部署、数据与模型全生命周期保密、算法代码自主可控的智能处理体系，是飞行器试验数据智能化转型不可逾越的底线，也是实现“能打仗、打胜仗”战略目标的技术保障。

在此背景下，本研究以本地化大模型为核心引擎，围绕“数据接入—智能解读—决策支撑”全流程，系统性地突破多源异构数据语义融合、跨

学科可解释性关联挖掘与智能决策辅助等关键技术，构建安全可控的飞行器试验数据智能处理体系。

研究的**理论意义**在于：第一，验证小参数量大模型在高度专业化的飞行器试验领域的深度适配方法论，揭示有限参数容量下领域知识高效注入与通用推理能力保持的内在机理，为“小模型解决大问题”提供理论依据和技术路线；第二，构建面向飞行器多物理场数据的跨模态统一语义空间，建立多学科数据的语义对齐机制，丰富多模态表征学习在工程科学领域的应用理论；第三，设计覆盖“数据输入→分析推理→决策输出”全链路的可解释性证据链机制，将大模型的隐式推理过程外化为可追溯、可验证、可审计的结构化因果图，为高风险场景下的 AI 辅助决策提供可信性保障理论框架；第四，将反事实推理和博弈论不确定性建模引入大模型决策过程，探索有限信息条件下的鲁棒性决策生成机制，丰富大模型驱动的智能决策理论。

研究的**实践意义**在于：第一，为飞行器研制试飞、体系对抗验证和战法推演评估提供高效、精准、安全的技术支撑，将单架次试飞数据处理周期从传统的数天压缩至一小时以内，实现试验数据处理效率提升 50%以上、关键决策建议准确率≥85%的核心目标；第二，通过构建完全本地化部署的智能处理系统，解决军事场景下数据安全与自主可控的刚性约束，为涉密环境下的大模型应用提供可复制的工程范式；第三，推动飞行器试验评估从“以人为主的经验堆叠”向“人机协同的数据智能”范式跃迁，将资深专家的隐性知识转化为可计算、可复用的领域知识库，缓解关键人才流失带来的知识断层风险；第四，切实缩短新型飞行器从工程研制到作战能力生成的周期，通过加速“试验-分析-改进-验证”的迭代闭环，支撑飞行器装备的敏捷研发与作战能力的快速形成，为抢占未来空天博弈制高点提供技术赋能。

（二）国内外研究现状级发展动态分析

1. 大模型在军事与试验数据处理中的应用研究

大模型技术正加速向军事领域渗透。EdgeRunner AI 于 2025 年发布了 EdgeRunner 20B 模型，基于 gpt-oss-20b 进行领域微调，在 1.6M 军事领域高质量数据上训练，在战斗兵种、战斗医疗、网络作战和通用军事知识四项测试集上达到与 GPT-5 相当的任务性能（95%以上统计显著性），证明小型本地化模型是军事等数据敏感领域的理想解决方案[1]。Molek 等（2025）提出了一种在战场物联网边缘设备上利用中型 LLM（如 Llama 3.1-8B）进行自然语言数据库交互的工作流，以图形数据库适配 IoBT 动态网络特性，将 LLM 同时用于自然语言到 Cypher 查询的转换以及数据库输出的自然语言摘要，在无需精确匹配数据库查询的条件下实现了较传统方法 19.4%的准确率提升[2]。Solanki 等（2026）进一步提出了面向 IoBT 任务编排的 PA-LLM-RAG 框架，在边缘设备上集成了检索增强推理与独立的命令验证机制（JudgeLLM），在确保低延迟响应的同时有效检测违反策略的命令[3]。

在领域微调方面，多项研究探索了军事领域 LLM 的适配方法。朱新立等（2025）提出了“武信”垂直领域大语言模型系统架构，采用 GaLore 策略对轻量级基座模型进行高效全参微调，在军事训练伤防治专业知识理解方面优于 LoRA 微调，在克服“幻觉”方面优势明显[4]。中国人民解放军 32802 部队（2025）提出了一种基于提示学习和 LoRA 微调 LLaMA3 的雷达装备领域知识抽取方法，在自建的 2800 条数据、近 120 万字的数据集上取得了显著效果[5]。此外，Sun 等（2025）在《指挥与控制学报》上提出了基于 LLM 的 C2 智能体与动态领域仿真环境决策方法，集成多模态感知、LLM 推理和动态知识图谱，在任务完成率和资源效率上优于传统系统[6]。

在兵棋推演与作战决策支持方面，Wang 等（2025）在《Defence Technology》发表了 Command-Agent 框架，将 LLM 与数字孪生战场深度整合，通过多模型协同架构（DeepSeek-R1 与 MCTool 解耦决策生成与命令执行），在红蓝无人机对抗中综合得分平均提升 41.8%，参战损耗比优

化 161.8%[7] 。 Chen 等 （ 2026 ） 在 Scientific Reports 上 提 出 了 Geo-Commander 框架，创新性地将 ReAct 推理机制与六边形网格空间编码相结合，在坦克分队作战模拟环境中显著优于控制组[8]。Palnitkar 等（2026）提出了 MilSCORE 基准，是首个面向 LLM 的军事场景级长上下文地理空间推理与规划评估数据集[9]。Liu 等（2025）提出了 WGSR-Bench，建立了首个面向 LLM 的博弈论战略推理基准，围绕环境态势感知、对手风险建模和策略生成三项核心任务系统评估 LLM 的战略推理能力[10]。在安全性评估方面，Johns 等（2026）提出了 ARMOR 2025 基准，以战争法、交战规则和联合伦理规范为锚定，对 21 个商用 LLM 进行评估，揭示了军事场景下安全对齐的关键缺口[11]。

在多源异构数据融合层面，军事科学院系统工程研究院提出了面向体系评估的多源异构数据关联方法（专利号 CN118093692A）[12]和多模态试验数据融合评估处理方法（专利号 CN120470521B）[13]，能够对测试数值序列、文本报告和结构化日志等多源试验数据进行统一关联与融合评估，为装备试验数据的智能化处理提供了工程化基础。

2. 大模型驱动的多源异构数据语义融合与对齐技术

面向多源异构数据的智能融合，Liu 等（2025）提出的 Cool-Fusion 方法无需额外训练即可融合多个异构大模型的知识，在数学推理基准 GSM8K 上实现 17.4%的准确率提升[14]。Gao 等（2025）提出的 Bohdi 框架利用合成数据和层次化多臂老虎机机制实现异构 LLM 的自动领域探索与融合，在多个基准上显著超越现有基线，已被 NeurIPS 2025 录用[15]。Tan 等（2025）提出的 Hydra 框架通过代理驱动的图拓扑与非结构化检索相结合，使用三因素跨源验证机制（源可信度评估、跨源印证和实体路径对齐），实现异构多源知识的深度融合与忠实推理，使 Llama-3.1-8B 达到接近 GPT-4-Turbo 的推理性能[16]。在跨源知识一致性校验方面，Tian 等（2025）在 ACL 2025 上提出了 CoRe-MMRAG 框架，遵循“内部响应生成→多源证据选择→外部响应生成→一致性整合”四阶段流水线，在

KB-VQA基准的InfoSeek和Encyclopedic-VQA上分别取得了5.6%和9.3%的性能提升[17]。

在表格与结构化数据的语义融合方面，Park等（2025）在ACL 2025上提出了HELIOS框架,创新性地结合了早融合的预对齐优势和晚融合的动态对齐灵活性，通过边级二分图子图检索避免无关上下文，同时引入星型图级别的LLM逻辑推理支持高级推理任务（如列聚合和多跳推理），在OTT-QA基准上召回率和nDCG分别提升42.6%和39.9%[18]。Hoseinzade等（2026）在ACL 2026上提出了TabEmb框架，创新性地将LLM语义编码与GNN结构建模解耦——由LLM为每列生成语义丰富的嵌入，再由GNN在图结构上注入列间关系，有效解决了传统BERT序列化方法的语义质量不足和二维到一维展平带来的结构退化问题[19]。Khoja等（2025）在EMNLP 2025上提出了Weaver框架，通过动态生成灵活的、逐步执行的SQL+LLM混合计划，实现结构化数据检索与语义处理的深度集成，在四个Table QA数据集上一致优于基线方法[20]。上述研究虽未直接面向装备试验领域,但其提出的跨源知识对齐与混合模态融合机制、表格-文本联合检索技术以及SQL+LLM混合推理范式，为解决试验数据中数值序列、文本报告与结构化指标之间的语义割裂问题提供了可迁移的技术路径。

3. 大模型驱动的智能决策与可解释性研究

智能博弈决策是近年来的研究热点。Karabag等（2026）通过变色龙游戏的理论与实证分析发现，LLM智能体在非合作场景中存在严重的信息控制能力不足——倾向于向身份未知的对手过度透露信息,同时揭示了内部表征中信息透露程度的线性编码结构,为通过表征干预增强博弈对抗能力提供了新思路[21]。He等（2026）提出了Strat-Reasoner框架，引入递归推理范式（一个智能体的推理过程中整合其他智能体的推理），并采用中心化思维链比较模块和组相对RL优化，在多种多智能体博弈中实现平均22.1%的性能提升[22]。

在动态环境决策方面，Sui 等（2025）提出的 WiA-LLM 框架训练 LLM 作为显式的语言世界模型，在特定环境中实现 74.2%的状态预测准确率（较基础模型提升 27%），其文本化的预测解释机制为可解释性决策提供了新范式[23]。Wang 等（2026）在 ACL 2026 上提出了 TriEx 框架，采用“第一人称自我推理—第二人称对手信念—第三人称环境参照”三视角对齐设计，将 LLM 的解释从自由文本叙事转变为锚定于证据的可比较对象，揭示了智能体“所说—所信—所做”之间的系统性偏差，强调可解释性是交互依赖的属性[24]。

在大模型推理可解释性方面，Luo 等（2026）在 Scientific Reports 上提出了面向可解释语言推理的多模态知识图谱框架，将不透明的 LLM 推理路径通过知识图谱中的结构化知识实体外化，实现可追溯、可审查的推理链输出，为高风险场景下的决策审计提供了方法论基础[25]。Lee 等（2025）在 ACL 2025 上提出了 H-STAR 混合 SQL-文本自适应推理算法，在表格理解中实现了符号推理与语义推理的两阶段统一[26]。

4. 大模型工具调用与智能代理技术

智能代理（LLM Agent）的工具集成与自主推理能力是构建“意图理解—工具路由—结果校验”链路的核心支撑。Yao 等（2023）在 ICLR 上提出的 ReAct 范式首次将推理与行动统一在同一框架中，通过交替生成思考轨迹与工具调用指令，显著提升了 LLM 在知识密集型任务中的表现，已成为后续 Agent 研究的基础范式[27]。

在工具调用能力方面，Liu 等（2026）提出了效用引导的 Agent 编排策略（Utility-Guided Agent Orchestration），将 Agent 编排建模为显式决策问题，通过平衡预估收益、步骤成本、不确定性和冗余度，在响应、检索、工具调用、验证和停止等行动之间进行选择，为工具调用质量-成本权衡提供了可控的分析框架[28]。Agarwal 等（2026）提出了 Switchcraft 模型路由器，首次将模型路由优化从对话补全扩展到工具调用场景，基于 DistilBERT 分类器实现“选择最低成本模型且保证正确性”，在五种函数调

用基准上节省 84%推理成本[29]。Sun 等（2026）提出了 When2Tool 基准和 Probe&Prefill 方法，发现 LLM 的隐藏状态中线性编码了工具必要性信号（AUROC 0.89-0.96），但模型生成时却无法有效利用这一内在知识——通过轻量级线性探针读取隐藏状态信号并预填充转向语句，将工具调用减少 48%而准确率损失仅 1.7%[30]。

在多工具编排方面，Xu 等（2026）发表了 LLM Agent 工具使用演进综述，系统性地将工具调用从孤立调用到长程多工具编排的核心问题归纳为六个维度：推理时规划执行、训练与轨迹构建、安全控制、资源约束下的效率、开放环境的能力完备性、以及基准设计与评估[31]。Kang 等（2026）提出了 SAGE 多智能体框架，将时间序列异常分析分解为点异常、结构异常、季节异常和模式异常四种专业化分析器，各分析器应用类型特定的数值工具和诊断可视化生成证据，再由检测器和监督器整合为置信度评分异常记录并转换为分析师可读的诊断报告[32]。

5. 大模型轻量化推理部署技术

本地化部署对模型的推理效率提出了严格要求。在极低比特量化方面，Lee 等（2025）提出的 LittleBit 框架通过潜在矩阵分解将权重表示为低秩因子并二值化，实现低至 0.1 BPW 的极端压缩——将 Llama2-13B 压缩至不足 0.9GB（约 31 倍内存缩减），已在 NeurIPS 2025 发表[33]。Nargund 等（2026）提出了 TernaryLM，以 1.58 比特有效精度的三元量化从零开始训练，在 MRPC 上以 82.47%的 F1 超越 DistilBERT[34]。Sanyal 等（2026）提出的 EntroLLM 在边缘设备上结合混合量化和熵编码实现了显著的存储节省[35]。

在推理加速方面，学术研究主要集中于权重压缩和算子优化路径。OSAQ（2026）框架通过二阶低秩性质引导的加法权重抑制实现低比特权重量化，FRM-PTQ 方法通过特征关系匹配增强量化后模型表征保真度，LBLLM 框架通过三阶段蒸馏实现大语言模型的轻量级二值化[36]。在系统层面，MLWQ 方法通过联合考虑层间损失和层内显著性的多级权重量

化实现 SLM 的高效部署[37]。

6. 现有研究的不足与本研究的必要性

综合以上分析，现有研究在以下方面仍存在明显不足，构成本研究的核心切入点：

（1）多源异构数据语义融合缺乏领域深度适配。

当前融合研究主要聚焦于通用领域知识对齐，缺乏面向装备试验领域的专业化适配——试验数据中的专业术语、测量语义和评估指标体系尚未在融合框架中得到有效建模。HELIOS、Weaver 和 TabEmb 等框架虽然在表格与文本融合上取得了突破，但其应用场景集中于开放域问答和科学文献，试验数据中特有的测试序列、工况标签和异常判定逻辑缺乏对应的语义对齐策略。

（2）可解释性关联挖掘与决策验证缺乏系统化方案。

现有 Agent 研究多聚焦于单环节推理或工具调用的可解释性，缺乏覆盖“数据输入→智能分析→决策输出→结果校验”全生命周期的证据链记录与追溯机制。TriEx 虽揭示了智能体“所说—所信—所做”的系统性偏差，但当前缺少将因果验证方法系统性地嵌入 Agent 工具调用链、实现端到端可审计能力的研究。

（3）轻量化推理与领域高性能之间存在矛盾。

虽然 EdgeRunner 20B 等研究证明了小模型可达大模型水平，但在参数≤8B 的约束下，同时实现多源数据理解、专业术语精准掌握和高速推理三者兼备的系统性方案仍属空白。LittleBit 和 TernaryLM 等量化研究侧重于通用能力保持，并未面向装备试验等知识密集型垂直领域进行适配验证。

（4）缺乏面向多人协同与全流程一体化的端到端系统框架。

现有研究多为单点技术突破，缺乏将多源数据接入、语义融合、智能代理推理、决策建议生成、证据链记录等能力在本地化环境中有机整合的端到端框架。Xu 等的综述指出，多工具 LLM Agent 的安全性和可验证性是当前开放挑战，但尚未有针对试验数据流批一体处理、多人并发协同以

及全生命周期安全保密的系统设计。

因此，本研究聚焦本地化大模型驱动的多源试验数据智能处理与决策辅助，系统性地解决上述关键技术问题，具有明确的理论价值和迫切的工程需求。

参考文献

[1] FitzGerald J, et al. EdgeRunner 20B: Military Task Parity with GPT-5 while Running on the Edge. arXiv preprint, arXiv:2510.26550v2, 2025.

[2] Molek C D, Venable K B, et al. Natural Language Interaction with Databases on Edge Devices in the Internet of Battlefield Things. arXiv preprint, arXiv:2506.06396, 2025.

[3] Solanki O, et al. Policy-Aware Edge LLM-RAG Framework for Internet of Battlefield Things Mission Orchestration. arXiv preprint, arXiv:2604.09493, 2026. (Accepted at AIS 2026)

[4] 朱新立, 高志强, 姬纬通, 李少华, 李松杰. 武信：一种垂直领域大语言模型系统架构设计与实证. 数据与计算发展前沿, 2025.

[5] 中国人民解放军 32802 部队. 基于提示学习的雷达领域知识抽取方法. 数据与计算发展前沿, 2025, 7(5): 184-197.

[6] Sun Z F, Zhou M Z, Liao L T, et al. LLM Based C2 Agent and Decision-making in Dynamic Domains Simulation Environment. Journal of Command and Control, 2025, 11(4): 445-458.

[7] Wang L, et al. Command-agent: Reconstructing Warfare Simulation and Command Decision-making Using Large Language Models. Defence Technology, 2026, 56: 294-313.

[8] Chen Y B, Ping Y, Zhou S, et al. A Framework of Large Language Model Commander Agent for Spatial Reasoning in Combat Simulation. Scientific Reports, 2026.

[9] Palnitkar A, et al. Mil-SCORE: Benchmarking Long-Context Geospatial Reasoning and Planning in Large Language Models. arXiv preprint, arXiv:2601.21826v3, 2026.

[10] Liu S, Fu Y, Yin Q, et al. WGSR-Bench: Wargame-based Game-theoretic Strategic Reasoning Benchmark for Large Language Models. arXiv preprint, 2025.

[11] Johns S, et al. ARMOR 2025: A Military-Aligned Benchmark for Evaluating Large Language Model Safety Beyond Civilian Contexts. arXiv preprint, arXiv:2605.00245, 2026.

[12] 中国人民解放军军事科学院系统工程研究院. 一种面向体系评估的多源异构数据关联方法和装置. 中国发明专利, CN118093692A, 2024.
[13] 于芹章, 巩向武, 邵婷娜, 卜广志. 一种多模态试验数据的融合评估处理方法和装置. 中国发明专利, CN120470521B, 军事科学院系统工程研究院系统总体研究所.
[14] Liu C, et al. Cool-Fusion: Fuse Large Language Models without Training. In: Proceedings of ACL 2025, 2025.
[15] Gao Y, et al. Bohdi: Heterogeneous LLM Fusion with Automatic Data Exploration. In: Advances in Neural Information Processing Systems (NeurIPS), 2025.
[16] Tan X, et al. Hydra: Structured Cross-Source Enhanced Large Language Model Reasoning. arXiv preprint, 2025.
[17] Tian Y, Liu F, Zhang J, et al. CoRe-MMRAG: Cross-Source Knowledge Reconciliation for Multimodal RAG. In: Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), 2025, pp. 32967–32982.
[18] Park S, Yun J, Lee J, Han W S. HELIOS: Harmonizing Early Fusion, Late Fusion, and LLM Reasoning for Multi-Granular Table-Text Retrieval. In: Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers), 2025, pp. 32424–32444.
[19] Hoseinzade E, Wang K, Durai Raju A. TabEmb: Joint Semantic-Structure Embedding for Table Annotation. In: Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics (ACL 2026), 2026.
[20] Khoja R, Gupta D, Fu Y, Roth D, Gupta V. Weaver: Interweaving SQL and LLM for Table Reasoning. In: Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing, 2025, pp. 28282–28308.
[21] Karabag M O, Sobotka J, Topcu U. Do LLMs Strategically Reveal, Conceal, and Infer Information? A Theoretical and Empirical Analysis in The Chameleon Game. In: Proceedings of the 25th International Conference on Autonomous Agents and Multiagent Systems (AAMAS 2026), 2026.
[22] He Y, et al. Strat-Reasoner: Reinforcing Strategic Reasoning of LLMs in Multi-Agent Games. arXiv preprint, arXiv:2605.04906, 2026.
[23] Sui Y, et al. What-If Analysis of Large Language Models: Explore the Game World Using Proactive Thinking (WiA-LLM). arXiv preprint, arXiv:2509.04791v2, 2025.

[24] Wang Z, et al. TriEx: A Game-based Tri-View Framework for Explaining Internal Reasoning in Multi-Agent LLMs. arXiv preprint, arXiv:2604.20043, 2026. (ACL 2026 Main)

[25] Luo J, Yu K, et al. Towards Explainable Language Reasoning via Multi-Modal Knowledge Graphs. Scientific Reports, 2026.

[26] H-STAR: LLM-driven Hybrid SQL-Text Adaptive Reasoning on Tables. In: Proceedings of ACL 2025, 2025.

[27] Yao S, Zhao J, Yu D, et al. ReAct: Synergizing Reasoning and Acting in Language Models. In: Proceedings of the 11th International Conference on Learning Representations (ICLR), 2023.

[28] Liu B, et al. Utility-Guided Agent Orchestration for Efficient LLM Tool Use. arXiv preprint, arXiv:2603.19896, 2026.

[29] Agarwal S, et al. Switchcraft: AI Model Router for Agentic Tool Calling. arXiv preprint, arXiv:2605.07112, 2026.

[30] Sun C E, et al. LLM Agents Already Know When to Call Tools -- Even Without Reasoning. arXiv preprint, arXiv:2605.09252, 2026.

[31] Xu H, et al. The Evolution of Tool Use in LLM Agents: From Single-Tool Call to Multi-Tool Orchestration. arXiv preprint, arXiv:2603.22862v2, 2026.

[32] Kang H, et al. Detecting Time Series Anomalies Like an Expert: A Multi-Agent LLM Framework with Specialized Analyzers. arXiv preprint, arXiv:2605.05725, 2026.

[33] Lee B, Kim D, et al. LittleBit: Ultra Low-Bit Quantization via Latent Factorization. In: Advances in Neural Information Processing Systems (NeurIPS), 2025.

[34] Nargund N, Shukla P. TernaryLM: Memory-Efficient Language Modeling via Native 1.5-Bit Quantization with Adaptive Layer-wise Scaling. arXiv preprint, arXiv:2602.07374v2, 2026.

[35] Sanyal A, et al. EntroLLM: Entropy Encoded Weight Compression for Efficient Large Language Model Inference on Edge Devices. arXiv preprint, arXiv:2505.02380v4, 2026.

[36] LBLLM: Lightweight Binarization of Large Language Models via Three-Stage Distillation. arXiv preprint, 2026.

[37] Hu C, He J H, Wu S Y, He Y X, Xue C J, Li Q A. MLWQ: Efficient Small Language Model Deployment via Multi-Level Weight Quantization. In: Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing (EMNLP), 2025, pp.

8067–8077.

二、研究内容

（一）研究目标

本研究以自主可控的本地化大模型为核心引擎，面向装备研发与博弈对抗验证中多源试验数据处理的核心痛点，构建覆盖“数据接入—智能解读—决策支撑”全流程的一体化智能决策框架。总体目标为：突破本地化大模型在试验数据领域的深度适配、可解释性关联挖掘与端到端决策闭环等关键技术，形成一套理论方法完整、技术自主可控、系统安全可用的多源试验数据智能处理解决方案。

（二）研究内容

针对指南要求，本项目聚焦本地化大模型驱动的多源试验数据智能处理与决策辅助框架研究，围绕多源数据格式异构性强，语义割裂验证，异常模式隐蔽多样，标记体系缺失，关键规则难以显式建模等关键问题，开展以下三方面具体研究： 1. 构建本地化大模型多源数据适配与高效推理部署技术；2. 大模型驱动的可解释性关联挖掘与决策验证技术；3. 本地化“感知—定位—决策—行动”智能决策框架构建。

研究内容一：本地化大模型多源数据适配与高效推理部署技术

本部分面向试验数据多源异构、语义割裂的痛点，研究本地化大模型在装备试验领域的深度适配方法。

（1）领域微调与知识注入技术。以自主可控的开源大模型为基础（参数量≤8B），研究面向试验领域的指令微调策略：构建高质量的试验领域语料库；采用“通用预训练→领域持续预训练→任务指令微调”三阶段训练管线，在注入领域知识的同时保持通用推理能力；引入 RAG 技术构建试验知识库，实现领域专业术语的精准理解与上下文感知。

（2）跨格式/跨模态异构数据统一表征解析。设计面向多源试验数据的统一语义表示框架：针对≥4 类异构数据源，构建模态适配层实现数据的自动识别、解析与语义编码；研究基于对比学习的跨模态对齐策略，将

异构数据映射至共享语义空间；解决不同采样率、不同尺度、不同精度的数据在语义层面的一致性表达问题。

（3）轻量化推理部署与性能优化。在参数约束下，研究面向单卡环境的高效推理部署方案：采用混合专家模型（MOE）架构大模型保证激活参数量小，但依旧有较强性能，采用动态量化（INT8/INT4）、知识蒸馏和算子融合等技术实现模型压缩；研究 KV-Cache 优化、批处理调度和流式推理策略，保障单卡推理速度≥60 tokens/秒；开发国产化硬件适配方案，确保完全本地化部署的可行性。

研究内容二：大模型驱动的可解释性关联挖掘与决策验证技术

本部分面向异常关联难以发现、决策依据缺乏透明度的痛点，研究可解释性推理与验证机制。

（1）意图理解—工具路由—结果校验”智能代理链路构建。设计面向试验数据分析的自定义工具集（统计分析工具、异常检测算法、关联规则挖掘、趋势预测模型等），并研究以下核心技术：一是意图理解模块，基于提示词工程和思维链推理，将用户的自然语言分析需求精准解析为结构化的分析任务序列；二是工具路由模块，研究动态工具选择策略，实现多种分析工具的自动化调用与协同编排，确保调用成功率≥95%；三是结果校验模块，对分析结果进行一致性检查、合理性验证和置信度评估，形成“分析—验证—反馈”闭环。

（2）可解释性证据链全生命周期管理。研究面向决策追溯的完整证据链捕获、记录与校验机制：设计证据链的数据结构模型，涵盖数据来源、处理步骤、分析方法、中间结果、决策依据等全环节；实现分析过程的可视化追溯，支持从决策结论反向溯源至原始数据；引入密码学哈希链确保证据链的不可篡改性，使决策过程具备可审计、可复盘、可归因能力，证据链记录完整度≥98%。

（3）决策准确性系统性提升方法。研究多方面提升决策建议准确率的技术策略：基于自一致性采样（Self-Consistency）增强推理鲁棒性；引

入反事实推理机制验证关键假设;设计领域特定的评估指标体系(准确率、召回率、决策时效性、推理链一致性),支撑95%以上准确率目标。

研究内容三:本地化"感知—定位—决策—行动"智能决策框架构建

本部分面向多人员协同和海量数据处理需求,研究端到端本地化系统架构与工程化方法。

(1)闭环链路设计与系统集成。打通"多元感知→目标定位→智能决策→自动执行"完整链路:感知层实现多源数据的自动化采集、格式识别与语义编码;定位层完成异常检测、趋势识别和关键指标定位;决策层基于智能代理生成分析报告和决策建议;执行层将决策结果以可视化报告、API推送等形式自动化输出。

(2)任务调度与流批一体处理优化。面向单批次1万行数据的处理需求:设计流批一体处理引擎,统一实时流数据和批量历史数据的处理逻辑;优化任务并行调度策略,通过计算图优化和流水线并行实现全流程处理时间≤60秒。

(3)高并发服务与多人协同机制。设计支持≥10个并发用户的系统架构:实现会话隔离与上下文管理,保障多用户操作的独立性;引入基于角色的访问控制(RBAC)和数据行级安全机制;优化共享推理引擎的资源调度,降低并发场景下的响应延迟。

(4)安全保密体系设计。实现100%本地化部署:全链路离线运行,杜绝数据外传;设计数据分级分类存储与加密传输机制;建立模型和数据的全生命周期保密管理流程。

(三)拟解决的关键科学问题

关键问题一:如何在不丢失模态特异性语义的前提下,建立多源异构试验数据的统一语义表征与跨源对齐?

装备试验数据包含数值序列、文本报告、结构化表格等多种模态,其各自的组织方式、语义粒度和噪声模式差异显著。直接将不同模态数据压缩到共享表示空间可能导致领域特定语义的严重损失——例如,时间序列

的局部模式与文本中的技术描述虽然指向同一物理现象，但其信号形态和抽象层级完全不同。核心科学挑战在于：设计一种既保持各模态内关键语义信息、又实现跨模态可计算对齐的表示学习框架。拟从以下路径突破：提出模态自适应的分层次编码策略——在底层保留模态特化的特征提取器（如时序卷积、表格注意力等），在中高层引入共享语义投影层，通过领域知识引导的对比学习逐步对齐跨模态语义；同时研究基于互信息最大化的弱监督对齐发现机制，利用少量人工标注的跨模态对应关系作为锚点，引导模型在海量无对齐标注数据上自主发现更多的对应模式；建立模态间语义鸿沟的量化指标——利用领域专家标注的语义相似度矩阵衡量对齐前后跨模态检索性能的增益，指导对齐策略的选择与优化。

关键问题二：在参数量≤8B 的强约束下，大模型如何同时兼顾通用推理能力与深度领域知识的精准掌握？

为解决这一矛盾，本研究拟采用混合专家（Mixture of Experts, MoE）架构作为基础模型结构。MoE 架构的核心优势是解耦总参数量与激活参数量：总参数可扩展至 8B 上限以容纳丰富的领域知识，但每次推理仅激活与当前输入最相关的一小部分专家，使实际推理开销远低于同等规模稠密模型。通过路由机制探测识别领域敏感专家子集，对其施加差异化 LoRA 适配以注入领域知识，同时冻结通用推理相关专家以保留原有能力，实现通用能力与领域知识的解耦优化，从而在严格控制推理成本的前提下突破小参数量模型的能力瓶颈。

关键问题三：如何将大模型隐式推理过程转化为结构化、可验证的证据链，以满足军事决策对可解释性和可审计性的刚性需求？

大模型推理具有“黑箱”特性，其内部运算由数十亿参数的数值计算构成，无法直接为人理解或审计。然而，在装备试验与博弈对抗场景中，决策建议必须可追溯到具体的数据依据和分析逻辑，以支撑决策责任归属和安全审查。核心科学挑战在于：将大模型的隐式推理过程外化为显式、结构化且可验证的证据链，并保证此外化过程的忠实性（不扭曲模型真实决

策逻辑）和完备性（覆盖全部关键推理步骤）。拟从以下路径突破：借鉴ReAct范式，要求模型在每一步外部工具调用时显式输出“当前观察→推理→行动”结构化三元组，将推理路径碎片化、可追踪；在此基础上，设计DAG证据链模型捕获全链路输入、操作与输出，通过密码学哈希链保证不可篡改；研究基于因果追溯的验证方法——利用模型内部激活修补（activation patching）和反事实输入干预，识别证据链中哪些步骤对最终结论具有因果决定性，建立推理忠实度评估分数，作为证据链质量的核心量化指标。

三、研究方案

（一）研究方法

本研究以本地化大模型为核心，面向飞行器试验与博弈对抗验证中的多源异构数据智能处理需求，构建覆盖“数据接入—智能解读—决策支撑”全流程的一体化决策辅助框架。整体研究方案从三个相互递进的层面展开：首先，解决基础的数据适配与模型高效推理问题，建立领域知识与异构数据的桥梁；其次，突破可解释性关联挖掘与决策验证技术，确保智能分析过程的透明与可信；最后，集成形成面向多人协同的端到端本地化决策系统，并通过典型场景验证整体效能。以下对各部分的具体方法、理论模型与关键公式进行详细阐述。

研究内容一：本地化大模型多源数据适配与高效推理部署技术

本部分的核心目标是解决飞行器试验数据“多源异构、语义割裂”的痛点，并实现有限计算资源下的高效推理。研究从三个维度展开：领域知识与指令的深度注入、跨模态数据的统一语义表征、轻量化部署与推理加速。

1. 领域微调与知识注入

飞行器试验领域具有高度的专业性和封闭性，通用大模型在气动参数、发动机喘振特征、隐身RCS时序规律等概念上表现不佳。为此，本研究设计了一套“通用预训练 → 领域持续预训练 → 任务指令微调”的三阶

段训练管线。基座模型采用混合专家（MoE）架构，该架构通过稀疏激活机制，在保持较大总参数容量的同时，将每次推理实际参与计算的参数量控制在与轻量级稠密模型相当的水平，从而兼顾领域知识存储与推理效率。

首先，收集构建高质量领域语料库。在此语料上进行持续预训练，采用自回归语言建模损失函数：

$$L_{LM}(\theta) = -\sum_{t} logP_{\theta}(x_t | \ x < t)$$

其中θ为模型参数，x_t为语料中的第 t 个 token。这一阶段使模型初步掌握领域术语、文本风格和隐含的物理概念关联。随后，进行多任务指令微调。构建涵盖“参数提取→趋势判读→异常识别→根因分析→报告生成”等典型任务的指令数据集，每条指令包含自然语言描述、上下文信息以及期望的输出。采用 LoRA（Low-Rank Adaptation）微调策略，将权重更新量约束为低秩形式：

$$W' = W_0 + \Delta W = W_0 + BA, A \in \mathbb{R}^{d \times k}, B \in \mathbb{R}^{d \times r}, A \in \mathbb{R}^{r \times k}, r \ll \min(d, k)$$

训练时仅优化A和B矩阵，原始权重W冻结，可训练参数量通常仅为全量的极小比例。这既避免灾难性遗忘，又可大幅降低显存开销，且不会增加推理时的计算负担。为了进一步提升专业术语理解的准确性，考虑引入检索增强生成（RAG）模块。将试验规范、故障案例库等文本切分后向量化，存入本地向量数据库。推理时，对用户查询q计算其嵌入$\mathrm{Emb}(q)$，检索最相似的k个文档片段：

$$\mathrm{Ret}(q) = TopK_{d \in D} \cos ine\left(\mathrm{Emb}(q), \mathrm{Emb}(d)\right)$$

检索到的上下文 C 与原始查询拼接后输入模型，模型在生成答案时同时依赖其参数化知识和外部知识库，有效降低“幻觉”概率，确保专业术语理解的高准确率。

2. 跨格式/跨模态异构数据统一表征解析

飞行器试验数据包含数值时间序列（如振动频谱、温度曲线）、文本报告（如故障描述、试飞日志）以及结构化表格（如传感器标定参数、外

挂物配置表）等多种模态。当前的大模型原生支持自然语言文本的输入，因此本研究将所有模态的数据统一转换为序列化的文本表示，直接输入模型进行处理。

对于数值时间序列，将其转换为带有物理量标签的数值列表字符串。例如，一段迎角时序数据表示为："迎角序列（单位：度）：2.3, 2.5, 2.7, 2.9, 3.1, …"。对于长序列，采用关键点采样或均匀降采样方式压缩至模型输入窗口内。对于结构化表格，将其转换为"列名：值"的键值对序列或简化的 Markdown 表格。例如，一个传感器标定表可表示为："传感器 ID：左发振动；量程：0–50 g；灵敏度：10.2 mV/g；标定日期：2025-06-01"。对于文本报告，直接保留原始文本。不同类型的输入通过明确的节标题或自然语言说明进行区分，例如在数据块前加上"【时序数据】"、"【表格数据】"等标记。

通过这种统一的序列化表示，数值、表格和文本被置于同一语义空间中。大模型的自注意力机制可以自动学习不同模态信息之间的关联：例如，振动时序中的尖峰位置与文本报告中的"异常振动"描述可能指向同一故障事件；表格中的传感器参数与时序数值的尺度之间需要建立隐含的换算关系。这些跨模态的对应关系无需外部对齐网络，完全由模型通过端到端的语言建模训练和指令微调自主掌握。

为了进一步增强模型对试验领域跨模态关联的敏感度，在指令微调阶段特意构造了需要结合多种数据类型的任务样本。例如，提供一段发动机转速时序、一份故障描述文本和一张传感器参数表，要求模型判断故障类型并给出依据。通过大量此类任务的训练，模型能够更加有效地利用统一序列化输入中的跨模态信息。

3. 轻量化推理部 4 署与性能优化

在本地化部署的硬件约束下，推理速度是决定系统实用性的关键指标。本研究从模型结构、量化策略和运行时调度三个层面进行优化。

在模型结构层面，基座模型的 MoE 架构通过稀疏激活实现高效推理。

设模型总共有 \(E\) 个专家网络，每个专家是一个前馈网络。对于每个输入 token，一个轻量级的门控网络$G(x)$输出概率分布$\mathbf{s}=[s_1,s_2,...,s_E]$，然后选择得分最高的前$k$个专家(通常 $k=1$ 或$k=2$,并将它们的输出加权求和:

$$y=\sum_{i\in \mathrm{TopK}(g(x))} g_i(x)\cdot E_i(x), \qquad g(x)=\mathrm{Softmax}(W_g x)$$

由于每个 token 仅激活少数专家，实际计算量远小于模型总参数量所暗示的水平，这使得在有限的计算资源内存储丰富的领域知识成为可能。

在量化策略方面，采用动态混合量化。对于大部分线性层权重，使用对称量化加零点漂移:

$$x_q=\mathrm{clamp}\left(\left\lfloor\frac{x}{\Delta}\right\rfloor+z,0,2^b-1\right),\Delta=\frac{\max(|x|)}{2^{b-1}-1}$$

其中x为原始浮点权重，x_q为量化后的整数，$\left\lfloor\frac{x}{\wedge}\right\rfloor$为取整操作，b 为量化比特数。对于注意力机制中的关键操作（如 softmax）和少数敏感层，则保持高精度，以平衡精度损失。在运行时，采用 KV-cache 优化：将已生成 token 的 Key、Value 矩阵$\mathbf{K}_{\text{cache}}$, $\mathbf{V}_{\text{cache}}$保存在显存中，对新 token t 的注意力计算简化为:

$$\mathrm{Attention}(\mathbf{Q}_t,\mathbf{K}_{\text{cache}},\mathbf{V}_{\text{cache}})=\mathrm{softmax}\left(\frac{\mathbf{Q}_t\mathbf{K}_{\text{cache}}}{\sqrt{d_k}}\right)\mathbf{V}_{\text{cache}}$$

这使得解码阶段的计算复杂度从$O(L^2)$降为$O(L)$，显著加速自回归生成。此外，结合动态批处理和流式推理策略，将多个用户的请求或同一用户的多个并发任务在 GPU 上合并为一个批次，最大化吞吐量。通过上述综合优化,在单张主流 GPU 上可实现满足实时辅助决策需求的推理速度。

研究内容二：大模型驱动的可解释性关联挖掘与决策验证技术

智能分析模型的不可解释性是其在高风险军事决策中应用的最大障碍。本部分旨在构建一个透明、可追溯、可审计的推理与决策机制，实现从“模型说黑话”到“模型写事实链”的转变。

1.“意图理解—工具路由—结果校验”智能代理链路

传统的试验数据处理依赖人工编写脚本或逐一调用各类分析软件，效率极低。设计一个基于 ReAct 范式的 LLM Agent，使其能够理解用户的自然语言分析需求，自主调用外部分析工具（如傅里叶变换、异常检测算法、关联规则挖掘、趋势预测模型等），并对工具返回结果进行合理校验。

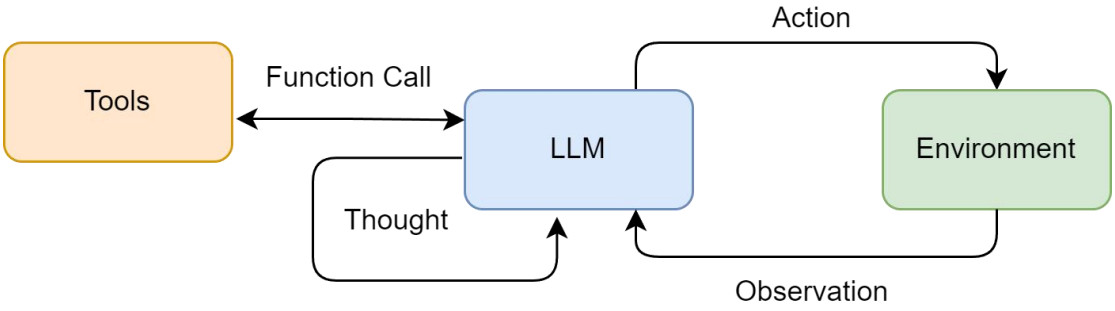


图 1 ReACT 智能代理工作范式

ReAct 范式将推理轨迹与行动轨迹交替生成。在一个分析任务中，模型维护一个历史轨迹序列：

$$\text{Traj} = \left[(\text{Thought}_1, \text{Act}_1, \text{Obs}_1), \ldots, (\text{Thought}_t, \text{Act}_t, \text{Obs}_t)\right]$$

在每一步，模型首先基于当前上下文生成一个“思考”（Thought），例如：“我需要先检查发动机转速时序是否存在周期性尖峰”。随后，模型生成一个“行动”（Act），例如调用工具 `peak_detection(series='N1_rotor', threshold=0.85)`。工具执行后返回的观测结果（Obs）被追加到上下文中，驱动下一步推理。这种显式的“思考-行动-观察”循环使得模型的每一步决策都有据可查，为后续的证据链构建奠定了基础。

工具路由的核心是让模型从预定义的工具集 $\mathrm{T} = \{T_1, \ldots, T_m\}$ 中选择最合适的一个并生成参数。本研究采用上下文学习与少量微调相结合的方法：首先在指令数据中对常见分析意图（如“找出过载超限的时间段”）与相应工具调用序列进行微调，使模型学会基本映射；推理时再通过提示词中给出的工具描述示例，引导模型完成泛化。将工具调用视为一个多分类问题，最优工具 T^* 和参数 $\therefore^*$ 满足：

$$(T^*, \therefore^*) = \arg\max_{T \in \mathrm{T}} P_{\mathrm{LLM}}(T \mid \text{Context})$$

通过对模型输出进行结构化解析和参数类型约束，确保工具调用成功率超过95%。结果校验模块是保证决策可靠性的最后一道防线。设计多层校验机制：第一层为语法与逻辑校验，检查工具调用参数是否合法、输出格式是否符合预期；第二层为跨源一致性校验，例如，若模型同时调用了两种不同的异常检测算法，需要对比它们的输出是否一致。

2. 可解释性证据链全生命周期管理

为了让决策过程真正做到“可追溯、可审计、可复盘”，设计一套基于有向无环图（DAG）和哈希链的证据链模型。每一个分析操作或推理步骤都映射为一个证据节点E_i，其数据结构定义为

$$E_i = \langle \mathrm{ID}_i, \mathrm{Type}_i, \mathrm{Source}_i, \mathrm{Operation}_i, \mathrm{InputHash}_i, \mathrm{Outpu\,tHash}_i, \mathrm{Timestamp}_i, \mathrm{PrevHash}_i \rangle$$

其中Type_i区分该节点是“数据加载”、“工具调用”、“模型推理”还是“人工审核”；Source_i记录原始数据文件或数据库表的路径；$\mathrm{Operation}_i$记录具体的操作参数（如傅里叶变换的窗函数类型、异常检测的阈值等）；$\mathrm{InputHash}_i$和$\mathrm{OutputHash}_i$分别是对输入数据和输出数据的SHA-256哈希值；$\mathrm{PrevHash}_i$是前一个证据节点的哈希值，从而将所有节点串联成一条防篡改的有向无环图（DAG）。证据链记录完整度定义为：

$$\text{完整度} = \frac{\text{实际捕获节点数}}{\text{DAG模板预定义应有节点数}} \times 100\% \geq 98\%$$

当Agent执行ReAct循环时，系统自动捕获每一步的Thought、Act和Obs，将其结构化后插入到证据链DAG中。最终，从用户的原始问题到最终决策建议，整条因果路径都被显式记录。

为了验证证据链的忠实性——即模型是否真的依据链上的信息做出了决策，而不是模型自己编造的理由——引入因果追溯分析方法，特别是激活修补（Activation Patching）技术。具体做法是：首先运行模型得到原始决策D及其概率$P(D)$，然后选择一个关键中间步骤E_k（例如某个Thought所对应的隐状态h_k）。进行反事实干预，将该步骤的隐状态替换为模型在“缺少该信息”的情况下（例如屏蔽掉某段重要的观测数据）计算

得到的隐状态h_k'。然后前向传播得到新决策概率$P(D|\ \mathrm{do}(h_k \leftarrow h_k'))$。该步骤对最终决策的因果影响定义为：

$$\mathrm{CausalImpact}(E_k) = |P(D) - P(D|\ \mathrm{do}(h_k \leftarrow h_k'))|$$

通过对证据链中的所有关键节点计算该指标，可以量化每个推理步骤的重要性，并筛选出那些实际上并未影响最终结论的“冗余解释”。这为评估证据链质量提供了核心量化指标：推理忠实度。在实际系统中，证据链以可视化图形和可查询的表格两种方式呈现，支持用户从最终结论反向溯源至原始数据行，并且每一条证据链均可导出为 PDF 报告用于归档和审计。

3. 决策准确性的系统性提升方法

决策建议的准确性直接关系到飞行器安全与战术有效性问题。本研究从多个维度系统性地提升决策准确率。第一，自一致性采样。对于复杂的推理问题（如多故障根因分析），采用链式思维提示，让模型生成多条不同的推理路径，然后对每条路径的最终结论进行投票。设模型对同一个问题生成M条推理链，得到结论集合$\{c_1, c_2, ..., c_M\}$，最终输出为：

$$c_{\text{final}} = \arg\max_c \sum_{i=1}^{M} \mathbf{1}(c_i = c)$$

该方法能够有效缓解单一路径的偶然错误。第二，反事实推理验证。在模型给出某个因果断言后，自动构建一个反事实场景，重新运行模型或调用数值仿真，观察结论是否显著变化。若变化幅度低于预设阈值，则原断言的可信度被调低，模型需要寻找替代解释。第三，构建领域特定的评估指标体系。除了通用的准确率、召回率外，引入“决策时效性”和“推理链一致性”两项指标，用于持续监控和优化模型表现。通过上述方法的综合运用，确保关键决策建议的高准确率。

研究内容三：本地化“感知—定位—决策—行动”智能决策框架构建

在完成核心算法与推理机制研发后，本部分聚焦于工程化集成，构建一个支持多人协同、高并发、全链路安全的端到端本地化决策系统。

1. 闭环链路设计与系统集成

将整个系统划分为四个逻辑层:“感知层”、“定位层”、“决策层”和“执行层”，形成完整的闭环。感知层负责从各类数据源（文件服务器、实时遥测流、数据库等）自动拉取新数据，通过内容一中的模态适配器进行格式识别、解析和语义编码。定位层对数据流进行快速初筛，标记出可能存在的异常区间或关键工况转换点,从而减少大模型需要处理的数据量。决策层即前两部分训练和部署的本地化大模型及 Agent，它接收定位层传递的关键数据片段和用户意图，生成详细的分析报告和具体的行动建议（例如“建议在下次飞行前检查左发振动传感器”)。执行层将决策结果以可视化仪表板、自动生成工单等形式输出,形成数据驱动的持续优化闭环。

2. 任务调度与流批一体处理优化

试验数据处理兼具流式（实时遥测）和批式（历史数据批量回放）两类场景。为了实现统一的开发运维，采用流批一体处理引擎（基于 Flink 或 Spark Structured Streaming），在 API 层面对流和批使用相同的 SQL/DataFrame 语义。对于批量数据的处理,系统的端到端延迟可分解为:

$$T_{\text{total}} = T_{\text{io}} + T_{\text{parse}} + T_{\text{infer}} + T_{\text{post}}$$

其中 T_{infer} 是大模型推理部分,占主导。尽管研究内容一的轻量化技术，单条样本的推理延迟已控制在较低水平，但对于大批量数据，仍需要对推理过程进行并行化和调度优化。具体地，采用计算图优化技术：将整个数据处理流水线建模为一个有向无环图,节点为数据处理算子(如数据加载、格式转换、模型推理、结果聚合)，边为数据依赖关系。调度器自动识别图中相互独立的节点，将其分配到不同的 CPU/GPU 线程上并行执行。对于模型推理部分，将大批量数据切分为多个小批次，利用 GPU 的并行能力同时处理，同时通过流水线并行将数据加载与模型推理重叠，最大限度隐藏 I/O 延迟。

3. 高并发服务与多人协同机制

系统需支持多用户并发访问,且每个用户可拥有独立的分析会话和上

下文。服务网关采用基于异步框架的事件循环模型，避免线程阻塞。后端推理引擎以多进程方式部署多个实例，每个实例占用一张 GPU 或一块 GPU 的部分显存。由于模型的稀疏激活特性，单张主流 GPU 可以同时运行多个推理实例，从而实现更高的并发吞吐。当用户请求到达时，由负载均衡器根据当前各实例的排队长度进行分配。

为了实现多用户协同，设计共享的“分析项目”概念：同一团队的用户可以加入同一个项目，共享已生成的证据链、中间结果和自定义分析模板。基于角色的访问控制（RBAC）将用户分为不同权限角色，对数据行、分析报告和系统配置进行细粒度权限管理。数据行级安全通过在每个数据表上附加标签（如密级、项目代码）并在查询时动态添加过滤条件来实现。对于高并发场景下的共享推理引擎，采用动态批处理策略：将等待队列中的多个用户请求的输入数据拼接成一个更大的批次，一次性送入 GPU 进行推理。由于 GPU 的并行能力，动态批处理显著降低了平均响应延迟，提升了系统吞吐量。

（二）技术路线

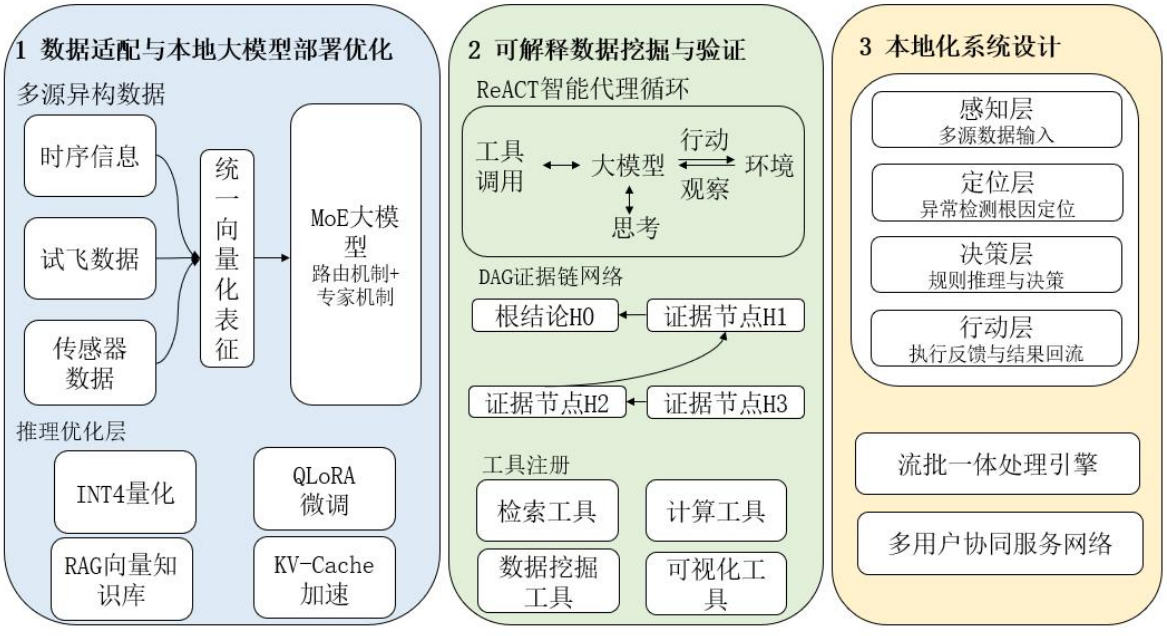


图 2 技术路线

本研究以本地化大模型为核心，面向飞行器试验与博弈对抗验证中的多源异构数据智能处理需求，构建覆盖“数据接入—智能解读—决策支撑”

全流程的一体化决策辅助框架。整体技术路线分为三个相互递进的阶段：

1、多源数据适配与高效推理部署

本阶段目标是解决数据异构性与计算资源限制问题，主要技术路径包括：

1) 领域微调与知识注入

- 构建飞行器领域语料库；
- 采用“通用预训练 → 领域持续预训练 → 任务指令微调”三阶段训练管线；
- 基座模型采用 MoE 架构，结合 LoRA 低秩微调与 RAG 检索增强，提升专业术语理解能力；

2) 跨模态统一表征

- 将数值时间序列、结构化表格、文本报告统一转换为序列化文本表示；
- 通过自然语言描述和节标题区分模态，利用大模型自注意力机制自动学习跨模态关联；

3) 轻量化推理部署

- 采用 MoE 稀疏激活、动态混合量化、KV-cache 优化、动态批处理等技术；
- 实现单张主流 GPU 上的高效推理，满足实时辅助决策需求；

2、可解释性关联挖掘与决策验证

本阶段目标是提升模型在高风险决策中的透明度与可信度，主要技术路径包括：

1) LLM Agent 智能代理链路

- 基于 ReAct 范式构建“思考-行动-观察”循环；
- 支持自然语言驱动的工具调用（如傅里叶变换、异常检测等），并集成二层结果校验机制（语法、一致性）；

2) 证据链全生命周期管理

- 构建基于 DAG 和哈希链的证据链模型，记录每一推理步骤；
- 采用激活修补技术量化各节点对最终决策的因果影响，计算推理忠实度；

3) **决策准确性提升**

- 引入自一致性采样、反事实推理验证、领域评估指标体系（如决策时效性、推理链一致性）；
- 确保关键决策建议的高准确率与鲁棒性；

3、端到端本地化智能决策系统集成

本阶段目标是实现工程化部署与多人协同，主要技术路径包括：

1) **闭环链路设计**

系统划分为感知层、定位层、决策层、执行层，形成数据驱动的闭环优化。

2) **流批一体处理**

- 基于 Flink 或 Spark Structured Streaming 实现流式与批式数据统一处理；
- 采用计算图优化与 GPU 并行调度，降低端到端延迟；

3) **高并发与协同机制**

- 异步服务网关 + 多进程推理实例 + 动态批处理，提升并发吞吐；
- 支持共享分析项目、RBAC 权限控制、行级数据安全，实现多人协同分析。

（三）可行性分析

1. 技术可行性

本研究采用的核心技术均有成熟的理论基础和工程实践支持。LoRA/QLoRA 参数高效微调技术在多项研究中验证了其以极小参数量（通常为主模型的 0.1%–1%）实现有效领域适配的能力，本研究中 r=16 的设置下可训练参数约为主模型的 0.3%。SmoothQuant 和 PagedAttention

分别有 vLLM 等开源推理框架的成熟实现可供参考和适配。ReAct 范式自 2023 年提出以来已成为 LLM Agent 的基础框架，LangChain 等工具链提供了标准化的集成接口。Merkle 树的不可篡改验证在区块链和版本控制系统中已有数十年工程实践。

从模型性能基线看，当前≤8B 的开源模型（如 Qwen3-8B、DeepSeek-R1-Distill-Qwen-7B）在多项通用基准上已接近更大模型的表现，结合领域微调和 RAG 增强，在知识密集型垂直任务上达到≥95%专业术语理解准确率的可行性高。

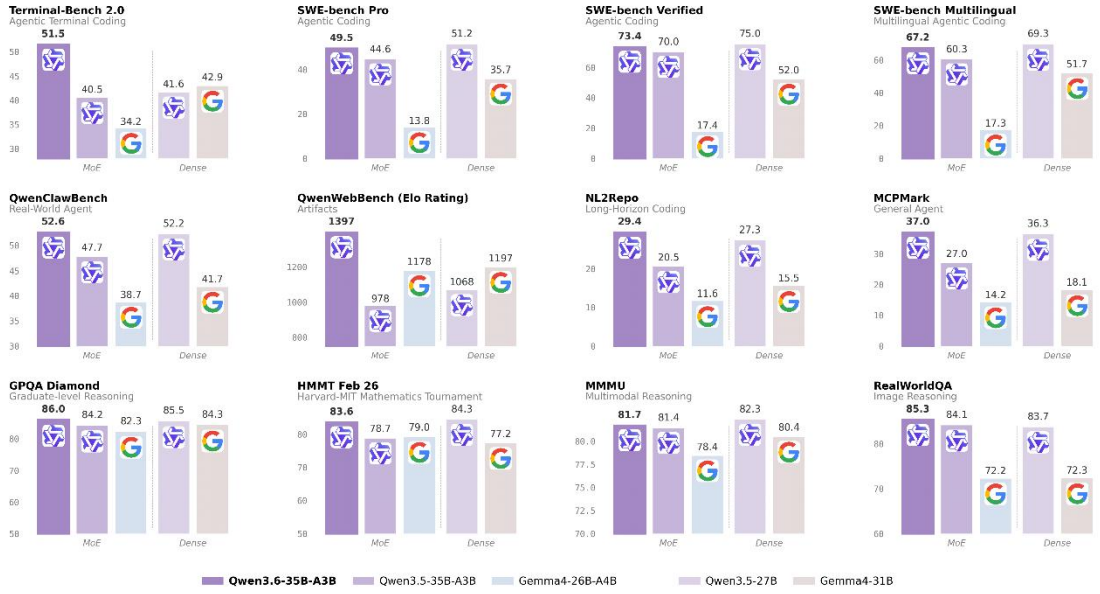


图 3　Qwen3.6-35B-A3B 在 AI 性能基准上的对比表现

2. 硬件环境可行性

单卡 NVIDIA RTX 4090（24GB 显存）或 A100（40GB 显存）已满足≤8B 模型的 INT4 量化部署需求。以 Qwen3-8B 为例，INT4 量化后模型权重约 4.5GB，加上 KV-Cache（PagedAttention 管理后估算≤10GB for 8K 上下文），总计显存占用≤15GB，留有充足余量供推理框架和工具链运行。训练阶段主要采用参数高效方法，梯度仅需为 LoRA 增量存储，相比全参微调节省约 97%显存。若采用国产算力，华为昇腾 910B（64GB HBM）的算力和显存指标均满足需求。课题组已配备必要的 GPU 计算资源。

3. 研究基础与条件保障

课题组在试验数据处理、智能决策系统领域具有扎实的研究积累，团队在试验评估与人工智能交叉领域具有丰富经验。

四、主要创新点

创新点一：面向试验领域的小参数量大模型全链路本地化适配方法

本研究创新性地在参数约束下构建面向装备试验领域的全链路适配方案，区别于现有研究多聚焦于单一环节（微调、推理或部署），本研究系统性地解决了“领域知识注入—跨模态表征—轻量化推理”三者的协同优化难题。核心创新在于提出了一种领域知识高效注入策略，在有限参数容量内实现专业术语理解准确率≥95%，为小模型在知识密集型垂直领域的深度应用探索可行路径。

创新点二：基于“意图理解—工具路由—结果校验”链路的可解释性证据链机制

本研究创新性地将智能代理的工具调用能力与可解释性审计需求深度整合，构建了覆盖分析全过程的证据链自动捕获与追溯体系。区别于现有可解释性研究多聚焦于注意力可视化或单步推理解释，本研究的全生命周期证据链机制实现了从原始数据到最终决策建议的完整因果链路记录，使决策过程具备可追溯、可审计、可复盘能力，为军事场景下的决策责任归属提供了技术保障。

创新点三：面向多人协同的“感知—定位—决策—行动”端到端闭环决策框架

本研究构建覆盖数据感知到自动执行的全闭环决策框架，打通传统数据分析和决策辅助中的断点。相比现有研究多停留于数据分析或决策生成的单一环节，本框架将实现流批一体处理、高并发服务和多人协同的工程化集成，使试验数据处理从传统的小时级人工流程压缩至≤60 秒的智能自动化流程，显著提升博弈对抗场景下的决策时效性。

五、年度研究计划及预期研究成果

（一）年度研究计划

1. 完成国内外文献的系统性调研，撰写综述报告；确定基础模型选型，完成本地化开发与实验环境的搭建与调试；同步启动试验数据的收集与脱敏清洗工作。

2. 完成多源异构数据集的标注；构建领域术语词典与知识图谱；开展领域持续预训练与多任务指令微调；同步设计并实现自定义分析工具集，启动“意图理解”模块的提示词工程构建。

3. 设计异构数据语义统一表征框架，完成跨模态对齐模型的训练与测试；完成模型轻量化压缩（INT8/INT4 量化）与单卡推理加速；开发“工具路由—结果校验”智能代理链路，实现工具的自动化调用与协同编排；构建证据链数据模型，实现分析过程的自动记录与可视化追溯。

4. 打通“感知—定位—决策—行动”端到端闭环链路，完成流批一体处理引擎开发与高并发服务测试（支持≥10 并发）；进行全模块集成联调，针对 1 万行数据进行全流程压力测试与性能优化（目标≤60 秒）；完成 100% 本地化安全保密体系部署；选取 2-3 个典型试验场景进行案例验证，对比传统人工处理流程评估效率提升效果（目标≥50%）；系统整理研究成果。

（二） 预期研究成果

1. 研究技术报告：研究技术报告 1 份；

2. 专利成果：专利交底书 1 份；

3. 仿真验证模型：交付一套完全本地化部署的“多源试验数据智能处理与决策辅助原型系统”，具备以下经过验证的核心能力：

1) 本地化大模型适配能力：支持≥4 类异构数据源的自动接入，模型对试验领域专业术语的理解准确率≥95%；数据后训练选取模型参数量≤8B，单卡推理速度≥60tokens/秒。

2) 智能分析与决策能力：大模型自设定分析工具调用成功率≥95%；给与关键决策建议准确率≥95%，决策过程可解释性证据链记录完整度≥98%

3) 系统性能与安全性：单批次 1 万行数据全流程处理时间≤60 秒；

系统支持并发用户数≥10；实现100%本地化系统部署，数据与模型全生命周期保密。

4. 国内外研究现状报告：1份。

六、研究基础

1. 数据处理、故障诊断及个体识别相关

1）针对多源试验数据的智能标记与挖掘技术研究

试验对抗数据的智能处理对于提升对抗策略能力和试验评估效能具有重要作用。在对抗场景下，飞行器试验数据的管理面临多类型、非统一格式及参数各异等复杂挑战，信息复杂度显著增加。针对这一问题，构建多源试验数据预处理-标记-验证-挖掘框架，通过数据的统一管理和预处理、数据的智能标记和关联规则挖掘，揭示感知-定位-决策-行动的闭环逻辑，为优化飞控系统参数和制定更精准的对抗策略提供有力支持。

a) 多源异构数据的融合统一管理

针对试验数据中结构化与非结构化数据并存、格式繁多、参数种类各异且命名规则不统一的现象，带来数据引用来源不清晰、检索困难，以及数据正确性、完整性和安全性难以有效掌控等突出问题。多源数据融合管理是通过整合不同来源、格式和结构的数据，构建统一视图以支持智能决策的过程。利用中间件或虚拟化技术整合这些结构化和非结构化数据，解决信息孤岛问题，支持对多源异构数据的导入、编辑、搜索、提取而无需物理的迁移数据。

b) 飞行试验数据优化预处理框架设计

针对原始飞行试验数据中存在的离群点干扰、噪声数据影响及数据不一致、不完整等突出问题，构建基于多变量时序数据补全技术与自编码器降维技术的联合处理框架，在保留数据特征的同时实现降维优化。首先采用自适应窗口滑动的多变量时序补全方法，通过动态调整窗口大小捕捉飞行姿态参数、环境变量等关键指标间的时序关联性，结合鲁棒统计模型（如Huber损失函数）有效识别并修正离群点，同时利用贝叶斯推理填补缺失

值，确保补全后的时序数据在时间维度上具有连续性和一致性；随后，构建基于变分自编码器（VAE）的深度降维模型，通过编码器将高维原始数据（如传感器读数、控制指令等）映射至低维隐空间，解码器重构数据时强制保留关键特征（如飞行轨迹稳定性、设备状态波动等），在降维过程中自动滤除噪声并强化数据内在结构，使降维后的数据既具备原始特征的表达能力，又显著降低计算复杂度。经此处理后的数据，为后续基于深度学习的聚类分析和智能标记提供了高质量输入。

c) 基于深度学习优化的对抗试验数据智能标记技术

试验数据具有静态或准静态时间序列长、数据多、利用价值低，但是动态和对抗数据时间序列短、数据少，利用价值高的特点。针对此问题，本项目拟采用置信推理策略生成高质量、类别均衡的训练集，构建基于重采样技术与深度学习优化的联合处理框架，以模型准确率、召回率为优化目标，迭代选择超参数组合（如学习率、批大小、网络层数），获取最优超参数配置，提升模型收敛速度和泛化能力，实现对数据的准确分类和标记。

d) 基于数据驱动的关联规则挖掘和可解释性建模

根据聚类和智能标记的结果，首先针对聚类后的每个簇拟采用 PSO、APriori 等机器学习算法，挖掘簇内的局部频繁项集与关联规则；再通过合并各簇的局部规则，并基于全局支持度、置信度等指标进行筛选，识别出跨簇的关联规则，实现对抗过程中感知、定位、决策和行动关联规则的挖掘，提升关联规则的可解释性，并完成数据的可视化呈现，为后续优化飞控和对抗策略提供支持。

2) 某型无人机动力分系统故障诊断研究

基于某型无人机动力分系统的故障注入平台与该无人机平台管理分系统获取数据集，利用无人机动力分系统的数据特征，采用 K 均值聚类算法和支持向量机设计故障诊断模型，并完成故障诊断验证实验。

为搭建诊断模型，首先详细分析该无人机动力分系统的数据，验证其

具有多维度、复杂性和非线性等特点，进而提出了利用机器学习进行故障诊断的思路，通过比较多种机器学习分类方式，最终确定使用 SVM 进行故障识别。

针对有标签的样本数据少，且希望能够实现在不重新训练所有数据的情况下识别新的故障类型的问题，提出先聚类后分类的半监督模型。详细对比多种聚类方式，最终选择 K-means 算法，该算法在原来数据集的基础上重新构建了高质量的训练数据集作为 SVM 分类器的输入。在训练过程中，每个 SVM 分类器使用带标签的数据进行训练，同时利用置信度高的伪标签数据不断优化分类器性能。为提高聚类的效果，利用主成分分析法从样本中提取出代表大部分信息的特征，去除冗余信息，使 K-means 能更加准确的找到每一簇的聚类中心，显著提升聚类的效果。

另外，还利用粒子搜索算法对 SVM 参数进行优化，最终经过验证，PCA_K-means 与 IPSO_SVM 算法结合的故障诊断模型，其故障识别率可以达到 97.6%。在此基础上，开发了一套针对无人机动力分系统故障诊断的软件，并使用真实的动力分系统运行数据进行了测试验证，结果表明该软件可以有效的进行故障诊断，具有很高的准确性和可靠性。

3) 无线通信辐射源个体识别

通信辐射源个体识别通过提取接收信号上的射频指纹特征,实现对目标个体的识别。现有辐射源识别技术存在特征提取无法应对复杂噪声环境,缺乏对新增未知辐射源设备识别等问题,导致低信噪比情况下识别率不高,实际应用受限。提出并解决：1)低信噪比环境下辐射源特征提取技术; 2)对新增未知类型设备进行分类识别的方法。研究成果能够用于通信对抗、敌我识别、无线网络安全、无线电监测等领域，具有重要学术及应用价值。

采用基于融合特征的未知辐射源非监督识别算法。对比传统特征提取方法和基于深度学习的特征提取方法在未知辐射源设备分类任务上的性能差异，实验结果显示传统特征提取方法识别效果更优。融合特征算法直接使用 I/Q 数据，利用矩形积分双谱和变分模态分解分别提取特征然后

进行特征融合，有效抑制高斯噪声，通过t-随机邻近嵌入降维避免维数灾难。并且研究了最优聚类数的计算流程，首先通过网格密度确定聚类数范围，再利用加权聚类指标计算得到最优聚类数，最后基于K-means聚类来分类识别。实验结果显示，该算法对8个未知辐射源的识别率为92.9%。

同时还研究了一种基于子域适应的跨接收机辐射源非监督识别算法。该算法基于残差网络提取特征，在残差块中引入注意力机制，并对常用残差网络结构进行改进，使其适用于辐射源信号的特征提取，利用局部最大平均差异度量源域和目标域特征之间的距离，将源域和目标域对齐。实验结果显示该算法在同型号射频传感器接收机间迁移后平均识别率达到84%以上。

2. 基于多模态大模型辅助的飞行器集成测试系统研究与实现

在现代航空航天工程中，飞行器总装配阶段的机载系统集成测试是确保整机可靠性和性能的关键环节。传统测试方法依赖人工判读驾驶舱显示器、指示灯和仪表，采用开环框架，效率低下、缺乏可追溯性，且易受人为误判影响；现有基于机器视觉（CNN/YOLO）或多传感器融合的自动化方案虽解决了人工识读效率低，缺乏可追溯性的问题，但在语义深度、可解释性仍存在显著不足，无法实现真正的“外部激励—机载响应—显控反馈”闭环自动判定。随着飞机系统复杂度不断提升，这些局限性已严重制约测试效率、显示判断一致性与工程可信度。

基于上述工程背景，本研究提出了一种面向飞行器总装配现场、以多模态大模型为核心进行视觉理解与推理的辅助飞行器集成测试系统。该系统通过对工业相机采集驾驶舱显控界面，并将面板内容、指示灯及仪表状态等视觉信息输入经相关数据集微调的大模型中，由其完成设备状态的识别与判断，从而实现对飞行器机载系统的闭环集成测试。为保证结果的可验证性与可追溯性，系统设计了证据链存储与可视化功能，可同步保存关键帧图像、识别文本、推理结论及对应的时间戳信息，供工作人员事后审阅。

具体研究包括:（1） 创新提出基于 Qwen3-VL-8B-Thinking 构建垂直飞行器集成测试领域的多模态视觉—语言协同推理框架，通过 235B 教师模型知识蒸馏生成伪标签，结合 QLoRA 监督微调与 GRPO 强化学习对齐，提升模型链式推理能力，实现从像素级观测到工程语义级判定的跨模态统一输出;（2）设计闭环判定机制，融合工程规则校验与人工复核的混合决策方法， 确保系统可靠性与可审计性;（3）搭建模块化全栈架构，采用边缘-中心分布式部署，实现多模态推理与证据链管理的闭环集成，并完成前端可交互;（4）在模拟总装环境及有限真实场景开展实验与消融分析。结果表明:状态识别准确率超过 98%，文本识别 F1 超过 0.97，时序对齐误差 0.32 s，证据链完整率高于 97%，整体性能优于传统 OCR、未微调大模型及常规视觉方法。

本研究为飞行器总装阶段机载系统集成测试提供了一种高效、可扩展、强可解释和工程可行的技术参考，在模拟与有限真实场景下有效缓解了人工依赖，提升了测试一致性与结果可追溯性。